

Laboratorijska vježba 09: Koraci JPEG kompresije

Za izradu laboratorijske vježbe treba koristiti odgovarajuću Jupyter Notebook datoteku. Urađenu vježbu je potrebno konvertirati u PDF format, a zatim je PDF datoteku potrebno predati do postavljenog roka koristeći platformu Zamger.

Ime i prezime studenta, broj indeksa: Ismar Muslić, 2366/19304

Datum izrade izvještaja: 24.5.2026.

Zadatak 1.

Za ovu vježbu je potrebno preuzeti testnu sliku Vijecnica.bmp koja se nalazi na C2 platformi neposredno ispod linka za ove vježbe. Ovu sliku je potrebno pozicionirati u isti direktorij u kojem se izvodi *ipynb file*.

Potrebno je implementirati funkciju JPEGKomp(B) koja kao ulazni argument uzima blok dimenzija 8x8 koji prikazuje vrijednost intenziteta piksela luminantne komponente Y. Funkcija nad blokom B izvodi sljedeće korake JPEG kompresije:

1. Od vrijednosti intenziteta piksela bloka B se prvo oduzima 128;
2. Nad blokom B se izvodi dvodimenzionalni DCT, što rezultira matricom DCTKoef koja sadrži DCT koeficijente. Za izvođenje 2D diskretne kosinusne transformacije (DCT) koristite funkciju `dct` iz modula `scipy.fftpack` (`from scipy. fftpack import dct`). Dvodimenzionalnu DCT nad blokom B možete dobiti na sljedeći način: `dct(dct(B, axis = 0, norm = 'ortho'), axis = 1, norm = 'ortho').astype(int)`. Primijetite da je funkcija `dct` pozvana dva puta imajući u vidu da jedan poziv ove funkcije izvodi DCT samo u jednoj dimenziji. Isto tako, primijetite da je napravljena konverzija u cjelobrojne vrijednosti.
3. Koristeći kvantizacijsku tabelu Q definiranu u kodu ispod izvesti kvantizaciju DCT koeficijenata na sljedeći način:

```
QDCTKoef[i][j] = round(DCTKoef[i][j] / Q[i][j])
```

Funkcija JPEGKoraci(B) kao ulazni argument prima blok B dimenzija 8x8 koji predstavlja intenzitet vrijednosti piksela luminantne komponente Y. Kao rezultat funkcija vraća dvije matrice: matricu DCT koeficijenata DCTKoef i matricu kvantiziranih DCT koeficijenata QDCTKoef.

Detaljan opis koraka JPEG kompresije možete naći u PDFmaterijalima na platformi C2 (poglavlje 6, str. 145-166).

Rješenje:

```
import numpy as np
import copy
import cv2
from matplotlib import pyplot
from matplotlib import image as mpimage # posto se koristi varijabla
image, pa dolazi do preklapanja
from scipy.fftpack import dct

# matrica sa kvantizacijskim koeficijentima
Q = [
    [16, 11, 10, 16, 24, 40, 51, 61],
    [12, 12, 14, 19, 26, 58, 60, 55],
    [14, 13, 16, 24, 40, 57, 69, 56],
    [14, 17, 22, 29, 51, 87, 80, 62],
    [18, 22, 37, 56, 68, 109, 103, 77],
    [24, 35, 55, 64, 81, 104, 113, 92],
    [49, 64, 78, 87, 103, 121, 120, 101],
    [72, 92, 95, 98, 112, 100, 103, 99]
]

def JPEGKomp(B):
    # JPEG kompresija nad blokom slike (8x8)
    # 1. oduzimanje 128 od vrijednosti piksela kako bi se vrijednosti
    skoncentrisale oko 0
    # 2. 2D DCT (cjelobrojna matrica koeficijenata DCTKoef kao
    rezultat)
    # 3. Kvantizacija (round(DCT[i][j]/Q[i][j])) - rezultat je
    QDCTKoef cjelobrojna matrica

    B_shifted = B.astype(float) - 128

    DCTKoef = dct(dct(B_shifted, axis=0, norm='ortho'), axis=1,
norm='ortho').astype(int)

    QDCTKoef = np.round(DCTKoef / Q).astype(int)

    return DCTKoef, QDCTKoef
```

Nakon implementacije funkcije, potrebno je izvesti programski kod ispod koji se odnosi na blok B1 tako da dobije prikazani ispis i grafički prikaz rezultata. Za izvođenje koda ispod biti će potrebno da imate instaliran modul CV2. Ako ovaj modul već nije instaliran, to možete napraviti npr. na sljedeći način: `pip install opencv-python`.

```
# učitavanje slike
path = "Vijecnica.bmp"
```

```

image = mpimage.imread(path).copy() # da ne bude readonly

# Označavanje bloka B1 crvenom bojom
height, width, channels = image.shape
pocetak1 = (7,7)
kraj1 = (16,16)
boja1 = (255,0,0)
debljina = 1
image = cv2.rectangle(image, pocetak1, kraj1, boja1, debljina)

# Označavanje bloka B2 zelenom bojom
pocetak2 = (18,100)
kraj2 = (27,109)
boja2 = (0,255,0)
image = cv2.rectangle(image, pocetak2, kraj2, boja2, debljina)

# Označavanje bloka B3 plavom bojom
pocetak3 = (150, 47)
kraj3 = (159, 56)
boja3 = (0,0,255)
image = cv2.rectangle(image, pocetak3, kraj3, boja3, debljina)

print("Testna slika: \nCrvenom bojom označen blok B1. \nZelenom bojom  
označen blok B2. \nPlavom bojom označen blok B3.\n")

pyplot.figure(figsize = (14,10))
pyplot.imshow(image)
pyplot.show()

# Blok B je definiran elementima slike pohranjene u matrici image
sadržanim u rasponu:
# image[pocetak[1]+1:kraj[1],pocetak[0]+1:kraj[0]]
# Napomena: pocetak[1] uvećavamo za 1 jer pravokutnik koji označava
blok nije sastavni dio bloka
B1=copy.deepcopy(image[pocetak1[1]+1:kraj1[1],pocetak1[0]+1:kraj1[0]])

print("\nGrafički prikaz bloka B1:\n")
pyplot.imshow(B1)
pyplot.show()

# Izračunavanje Y komponente bloka B1
R, G, B = B1[:, :, 0], B1[:, :, 1], B1[:, :, 2]
B1Y = (0.2989 * R + 0.5870 * G + 0.1140 * B).astype(int)

print("Vrijednosti intenziteta piksela luminantne komponente Y za blok  
B1:\n")
print(B1Y)
print("\nGrafički prikaz luminantne komponente Y za blok B1:\n")
pyplot.imshow(B1Y, cmap='gray', vmin=0, vmax=255)
pyplot.show()

```

```
DCTKcoef1,QDCTKcoef1 = JPEGKomp(B1Y)
print("\nDCT koeficijenti Y komponente za blok B1:\n")
print(DCTKcoef1)
print("\nKvantizirani DCT koeficijenti Y komponente za blok B1:\n")
print(QDCTKcoef1)
```

Testna slika:


Crvenom bojom označen blok B1.

Zelenom bojom označen blok B2.

Plavom bojom označen blok B3.




Grafički prikaz bloka B1:



Vrijednosti intenziteta piksela luminantne komponente Y za blok B1:

```
[[68 67 67 70 69 68 70 70]
 [67 67 68 69 68 68 70 69]
 [70 68 69 68 67 69 68 69]
 [71 69 69 69 68 69 69 71]
 [70 70 70 69 71 70 70 68]
 [70 70 69 68 71 70 70 69]
 [71 72 72 72 70 71 70 71]
 [70 72 72 71 72 73 70 70]]
```

Grafički prikaz luminantne komponente Y za blok B1:



DCT koeficijenti Y komponente za blok B1:

```
[[-467    0    0    0    0    0    0    0]
 [  -8   -2    1    0    1    2    0    0]
 [   1   -1   -1   -1    0    0    0    0]
 [   0    0    0    0    0    0   -2    1]
 [   1    0    0    0    0    0    0    0]
 [   1    0    2   -1    1    0    0   -1]
 [  -1    0    0    1    0    0    0    0]
 [   0    1    0    0    0    0    0    0]]
```

Kvantizirani DCT koeficijenti Y komponente za blok B1:

```
[[-29    0    0    0    0    0    0    0]
 [  -1    0    0    0    0    0    0    0]
 [   0    0    0    0    0    0    0    0]
 [   0    0    0    0    0    0    0    0]
 [   0    0    0    0    0    0    0    0]
 [   0    0    0    0    0    0    0    0]
 [   0    0    0    0    0    0    0    0]
 [   0    0    0    0    0    0    0    0]]
```

Nadalje, potrebno je izvesti programski kod ispod koji se odnosi na blok B2 tako da dobije prikazani ispis i grafički prikaz rezultata. Osim toga, potrebno je dodati i testiranje za **proizvoljno**

odabrani blok B3 koji na testnoj slici prikazanoj iznad treba biti označen **plavom bojom**.
Rezultati testa za blok B3 trebaju imati iste elemente kao i testovi za blokove B1 i B2.

```
# Blok B2
B2=copy.deepcopy(image[pocetak2[1]+1:kraj2[1],pocetak2[0]+1:kraj2[0]])


print("\nGrafički prikaz bloka B2:\n")
pyplot.imshow(B2)
pyplot.show()

# Izračunavanje Y komponente bloka B2
R, G, B = B2[:, :, 0], B2[:, :, 1], B2[:, :, 2]
B2Y = (0.2989 * R + 0.5870 * G + 0.1140 * B).astype(int)

print("Vrijednosti intenziteta piksela luminantne komponente Y za blok B2:\n")
print(B2Y)
print("\nGrafički prikaz luminantne komponente Y za blok B2:\n")
pyplot.imshow(B2Y, cmap='gray', vmin=0, vmax=255)
pyplot.show()

DCTKoef2, QDCTKoef2 = JPEGKomp(B2Y)
print("\nDCT koeficijenti Y komponente za blok B2:\n")
print(DCTKoef2)
print("\nKvantizirani DCT koeficijenti Y komponente za blok B2:\n")
print(QDCTKoef2)
```


Grafički prikaz bloka B2:



Vrijednosti intenziteta piksela luminantne komponente Y za blok B2:

```
[[177 178 179 188 185 188 190 187]
 [111 121 157 173 171 172 169 168]
 [ 76  75  77  81  85  86  87  87]
 [ 86  82  74  83  84  84  84  83]
 [175 174 175 190 186 189 192 193]
 [176 177 176 186 188 189 191 189]
 [ 72  72  74  90  89  89  93  89]
 [ 67  67  74  86  89  90  89  86]]
```

Grafički prikaz luminantne komponente Y za blok B2:



DCT koeficijenti Y komponente za blok B2:

```
[ [ 12 -56 -23  1  7  8 -3 -5]
  [ 118 -4 -7 -6 -2  0  4  1]
  [ -16 -14 -14 -4 -2  2  2  1]
  [ 323  1  3 -1  0  1 -2 -2]
  [  27 15 12  5  1  0 -2 -2]
  [-166 25 19  9  0 -2 -5 -1]
  [  34 17 15  6 -2 -4 -1  0]
  [  -7  2  6  0  0  0 -1  0]]
```

Kvantizirani DCT koeficijenti Y komponente za blok B2:

```
[ [ 1 -5 -2  0  0  0  0  0]
  [10  0  0  0  0  0  0  0]
  [-1 -1 -1  0  0  0  0  0]
  [23  0  0  0  0  0  0  0]
  [ 2  1  0  0  0  0  0  0]
  [-7  1  0  0  0  0  0  0]
  [ 1  0  0  0  0  0  0  0]
  [ 0  0  0  0  0  0  0  0]]
```

Blok B3

```
B3=copy.deepcopy(image[pocetak3[1]+1:kraj3[1],pocetak3[0]+1:kraj3[0]])
```

```

print("\nGrafički prikaz bloka B3:\n")
pyplot.imshow(B3)
pyplot.show()


# Izračunavanje Y komponente bloka B3
R, G, B = B3[:, :, 0], B3[:, :, 1], B3[:, :, 2]
B3Y = (0.2989 * R + 0.5870 * G + 0.1140 * B).astype(int)

print("Vrijednosti intenziteta piksela luminantne komponente Y za blok B3:\n")
print(B3Y)
print("\nGrafički prikaz luminantne komponente Y za blok B3:\n")
pyplot.imshow(B3Y, cmap='gray', vmin=0, vmax=255)
pyplot.show()

DCTKoef3, QDCTKoef3 = JPEGKomp(B3Y)
print("\nDCT koeficijenti Y komponente za blok B3:\n")
print(DCTKoef3)
print("\nKvantizirani DCT koeficijenti Y komponente za blok B3:\n")
print(QDCTKoef3)

```


Grafički prikaz bloka B3:



Vrijednosti intenziteta piksela luminantne komponente Y za blok B3:

```
[[ 67 208 192  32  74  36 210 171]
 [ 68 203 193  38 122  37 208 193]
 [ 89  49  60 133  80  97  43  56]
 [161  56  75  49  40  93  56  67]
 [ 61  26  40  42  38 168  31  20]
 [135  35  46 124  41 200  33  29]
 [ 54  49  75 145 121  60  48  43]
 [ 32  38 121  22  38  38  28  37]]
```

Grafički prikaz luminantne komponente Y za blok B3:



DCT koeficijenti Y komponente za blok B3:

```
[[ -364   18    9   -8  -53   10   44    6]
 [  181  -29  129  -98  -73  -43  -92   79]
 [   79  -15   41 -168  -68  -51  -98  120]
 [   66  -25   11   29  -48    0   -2  -34]
 [  -67    6   67   -7  -62  -13   29   37]
 [    5   34  -17    5   64   33  -19  -13]
 [  -44   19  -23   52   12   38   55  -72]
 [  -58  -23  -79    3   16   -6  -15  -24]]
```

Kvantizirani DCT koeficijenti Y komponente za blok B3:

```
[[-23  2  1  0 -2  0  1  0]
 [ 15 -2  9 -5 -3 -1 -2  1]
 [  6 -1  3 -7 -2 -1 -1  2]
 [  5 -1  0  1 -1  0  0 -1]
 [ -4  0  2  0 -1  0  0  0]
 [  0  1  0  0  1  0  0  0]
 [ -1  0  0  1  0  0  0 -1]
 [ -1  0 -1  0  0  0  0  0]]
```